

AIPA

기술 파이프라인 명세서

AI 가상 패널 설문 시뮬레이션 및 반응 예측 플랫폼
기술 구조, 데이터 처리 프로세스 및 시스템 아키텍처 상세

📅 2026.03.23 (최종 업데이트)

🔗 Version 0.1.0 (MVP Completed)

📄 예비창업패키지 사업계획서 기술 파트 작성용

👤 기획/개발팀 내부 공유 자료



작성 가이드: 본 문서는 예비창업패키지 제안서의 '실현가능성(기술성)' 항목 작성을 위한 기술 상세 자료입니다. 사업성 및 마케팅 관련 내용은 포함되어 있지 않으며, 핵심 기술의 구현 방식과 구조적 특징을 중심으로 서술되었습니다.

서비스 구성 및 기술 정의

AIPA 모바일 앱 내 핵심 2대 기능 기술 명세 요약



설문 시뮬레이션

N명의 AI 패널 기반 정량/정성 데이터 생성

기능 정의

KOSIS 인구통계 기반으로 생성된 가상 패널(Persona)이 업로드된 PDF 설문지에 대해 실제 사람처럼 응답하고 결과를 예측하는 시뮬레이션 환경

처리 방식

- 자체 임베딩 모델**: 페르소나 속성 벡터와 설문 문항 벡터 간의 유사도/적합도를 계산하여 응답 확률(점수) 예측 (0.01s)
- 경량 LLM (0.5B)**: 예측된 점수를 바탕으로 선택 이유를 자연어로 생성 및 JSON 포매팅 (3~10s)

출력 데이터

응답 분포 통계(Chart), 개별 패널의 선택 사유(Text), 원시 데이터(CSV)

🔗 자체 모델 100% (On-Device/Cloud Run CPU)



AI 채팅 (1:1 Interview)

특정 페르소나와의 심층 질의응답

기능 정의

사용자가 설정한 특정 페르소나(Target User) 1명과 1:1 채팅 인터페이스를 통해 비정형 데이터를 수집하는 심층 인터뷰 기능

처리 방식

- RAG & Context Injection**: 사용자가 업로드한 문서/이미지(기획서, 시안)를 컨텍스트로 주입
- Role-Playing Prompt**: 페르소나의 성격, 말투, 가치관을 프롬프트 시스템 메시지로 주입하여 답변 생성

출력 데이터

대화 로그(Text), 피드백 요약, 멀티모달(이미지) 인식 결과

☁️ Hybrid (Claude API + 자체 필터링)

설문 시뮬레이션 사용자 흐름

사용자 관점 프로세스 정의 (User Process Definition)

1



패널 선택

시뮬레이션 타겟 AI 페르소나 그룹 정의 및 속성 설정

- Preset 선택: MZ세대, 전문가 등 사전 정의 그룹 호출
- Custom 설정: 연령, 성별, 직업, 성격 변수 직접 입력

2



설문지 업로드

비정형 설문 데이터의 구조화 및 문항 추출 처리

- Input: PDF/이미지 등 비정형 문서 파일 인식
- Parsing: 질문/보기/테이블 구조 자동 추출 및 데이터화

3



시뮬레이션 실행

AI 페르소나 기반 가상 응답 생성 및 추론 실행

- Processing: 페르소나별 개별 인스턴스 추론 병렬 처리
- Monitoring: 실시간 진행률 (Progress) 및 상태 추적

4




결과 확인

통계 분석 데이터 및 개별 응답 근거 (Reasoning) 도출

- Output 1: 문항별 응답 분포 및 기초 통계 시각화
- Output 2: 개별 페르소나 선택 사유 (Natural Language) 및 Raw Data(CSV)

설문 시뮬레이션 내부 기술 흐름

반응 점수 예측 및 자연어 생성을 위한 6단계 데이터 처리 파이프라인 (Technical Specification)



AI 채팅 기술 구조

Context Injection 기반의 페르소나 시뮬레이션 및 멀티모달 처리 파이프라인

Process Pipeline



① Context Injection

페르소나 속성값(JSON)
시스템 프롬프트 주입



② Multi-modal Input

텍스트/이미지(Vision)
벡터 변환 및 분석



③ Role-Playing Logic

Claude 3.5 Sonnet API
페르소나 톤앤매너 생성



④ Structured Output

Markdown/JSON 포맷
구조화된 답변 반환



Dynamic Persona Prompting

KOSIS 인구통계 데이터를 기반으로 생성된 페르소나의 속성(나이, 직업, 성격 등)을 시스템 프롬프트에 동적으로 주입하여 일관된 답변 생성.

System Prompt

Context Window



Vision API Integration

업로드된 이미지(기획서, 시안)를 Vision 모델로 분석하여 시각적 정보를 텍스트 컨텍스트로 변환, 페르소나의 시각적 평가 수행.

Claude Vision

OCR



RAG (Retrieval-Augmented Generation)

사용자가 업로드한 문서(PDF, PPT)를 청킹(Chunking)하여 벡터 DB에 저장하고, 질문 관련 내용을 검색하여 답변에 참조.

Vector DB

Similarity Search



Structured Response Mode


자유 대화 외에 평가(Evaluation), 점수화(Scoring), 개선안(Suggestion) 등 목적에 따른 출력 포맷을 템플릿화하여 제공.

JSON Output

Zero-shot


설문 시뮬레이션 처리 구조

자체 모델 간 역할 분담 및 데이터 처리 파이프라인 (Model Interaction Flow)



자체 기술 스택

5가지 핵심 기술 요소 및 주요 성능 지표 (참고자료)



페르소나
임베딩 모
델

Predictive

22,862

파라미터

0.01s

추론(CPU)

104KB

사이즈

소비자 반응(0~100점) 정량 예측 초경량 모델.
Knowledge Distillation 학습 적용. GPU 미사용.



자체 학습
경량 LLM (0.5B)

Generative

Qwen 2.5

Base Model

2.8GB

메모리

3~10s

응답시간

임베딩 점수 기반 선택 이유 및 답변 자연어 생성.
자체 파인튜닝(LoRA)으로 한국어/페르소나 최적화.



학습 데이터셋

4,327건

평가 2,925 + 설문 1,402

Claude 3.5 기반 Knowledge Distillation.
한국 소비자 반응 합성 데이터 구축.



인간 편향 엔진

8 Types

Bias Models

극단 회피, 목종, 사회적 바람직성 등 실제 설문 응답 왜곡
패턴 시뮬레이션 적용.



트렌드 보정

Real-time



Naver DataLab

네이버 데이터랩 검색량 연동.
실시간 사회적/시대적 맥락 반영 RAG 시스템.


모델 독립성 구조 및 장애 대응

API 의존성 최소화 및 단계별 백업 시스템 기술 아키텍처

자체 모델 처리 영역 (Local Processing)



외부 API 의존 영역 (API Dependency)



● 자체 기술 (독립 실행) ● 외부 API (종량제)

모델 추론 장애 대응 (Failover)

자체 모델 추론 실패 시 API로 자동 전환, API 실패 시 룰베이스 템플릿으로 응답 생성의 연속성을 보장합니다.

Primary	→ 자체 모델 (0.5B LLM)	Default
Fallback 1	→ Claude API 호출	API
Fallback 2	→ 템플릿 기반 생성	Rule-based

데이터 저장소 장애 대응

Firestore 등 외부 DB 장애 발생 시 인메모리 임시 저장소로 전환하여 서비스 중단 없이 데이터를 보존합니다.

Storage	→ Google Firestore	Cloud
Failure	→ 인메모리 임시 캐싱	Local Cache

기술 로드맵

단기적 성능 고도화에서 장기적 글로벌 확장까지 단계별 성장 전략

Current Phase

MVP (현재 완료)

- ✓ 자체 임베딩+0.5B LLM 완성 (설문 전 파이프라인 자체 모델)
- ✓ 8가지 인간 편향 엔진 + 캘리브레이션 적용
- ✓ 네이버 데이터랩 트렌드 보정 연동
- 📱 Android 앱 베타 진행 (Cloud Run 배포)

핵심: 자체 모델 파이프라인 검증

Short Term

단기 (3개월)

- 🎯 실제 설문 결과 vs AI 예측 비교 검증 리포트 공개
- 🍏 iOS 앱 공식 출시 및 스토어 등록
- 🕒 설문 응답 속도 최적화 (배치 추론)
- 📊 초기 유저 피드백 데이터 수집 파이프라인 구축

핵심: 신뢰도 검증 & 멀티 OS

Mid Term

중기 (6개월)

- 🏠 채팅 기능도 자체 모델로 대체 (외부 API 의존 0%)
- 📁 학습 데이터 10,000건+ 확보 및 모델 재학습
- ✍️ 유저 피드백 기반 모델 자동 개선 (RLHF 도입)
- 💻 기업용 웹 대시보드 (B2B) 베타 오픈

핵심: 기술 독립성 & 데이터 확장

Long Term

장기 (1년)

- 📁 B2B SaaS 정식 서비스 런칭 (구독 모델)
- 🔧 실시간 A/B 테스트 시뮬레이션 기능 추가
- 🌐 글로벌 확장 (다국적 페르소나 데이터셋 구축)
- 🏢 API 서비스 개방 (외부 기업 연동 지원)

핵심: 수익화 & 글로벌 스케일업

핵심 기술 지표 (Core Specs)

AIPA Engine v0.1.0 기술 명세 및 운영 환경 요약



Embedding Model

22,862 Params

모델 크기 104KB. 반응 점수 예측 전용.
온디바이스 동작 가능한 경량 구조.



Lightweight LLM

0.5B Model

Qwen 2.5-0.5B 기반 파인튜닝.
CPU 환경 최적화 (Memory 2GB).



Latency (CPU)

0.01s / 3~10s

임베딩 예측 0.01초, 답변 생성 3~10초.
GCP Cloud Run CPU 환경 기준.



Accuracy

8.7 MAE

반응 점수 예측 평균 절대 오차.
100점 만점 기준 평가 지표.



Dataset

4,327 Samples

Knowledge Distillation 합성 데이터.
평가(2,925) + 설문(1,402) 데이터셋.



Infrastructure

Cloud Run Serverless

GCP Cloud Run + Firestore (NoSQL).
Android 베타 앱 배포 완료.

임베딩 모델 (반응 점수 예측)

소비자 반응을 0.01초 만에 수치화하는 초경량 자체 모델

모델 입출력 및 개발 과정



학습 데이터셋 구성 (4,327건)

16종 카테고리 (식품/앱/정책 등)	124개 자극물 (제품/서비스)
40명 페르소나 (연령/성별/직업)	94개 설문 질문 유형

모델 성능 명세 (Specs)

모델 크기	104 KB (초경량)
파라미터 수	22,862 Params
평균 예측 오차	8.7점 (100점 만점 기준)
추론 속도	0.01초 (API 호출 대비)
API 의존성	None (완전 독립)

경량 LLM 개발 과정 (Technical Detail)

자체 파인튜닝을 통한 한국어 특화 경량 모델(0.5B) 구축 및 최적화

Base Model & Fine-tuning Strategy

Base Model Selection

Qwen 2.5-0.5B (Instruct)

한국어 이해 능력 보유, CPU 추론에 최적화된 0.5B 파라미터 크기, 상업적 이용 가능 라이선스(Apache 2.0 등) 고려하여 선정

Fine-tuning Method

LoRA (Low-Rank Adaptation)

전체 파라미터의 약 1%만 학습하여 VRAM 요구량 최소화

Training Infrastructure

RTX 4070 Ti (1 GPU)

단일 소비자용 GPU로 1시간 내 학습 완료, 전기세 수준 비용

Training Dataset

Data Source (Knowledge Distillation)

Synthetic Consumer Reaction Data (4,327 ea)

Claude 3.5 Sonnet을 통해 생성된 고품질 합성 데이터. 16개 카테고리, 124개 자극물에 대한 40종 페르소나의 상세 반응 포함

Target Tasks



Reasoning Generation

예측 점수(Score) 기반의 구체적 선택 이유 자연어 생성



Structured Output (JSON)

설문 응답 처리를 위한 JSON 포맷 강제 출력 학습

Deployment & Performance

Production Environment

Google Cloud Run (Serverless Container)

CPU

GPU Free Operation

2GB


Memory Usage

3~10s

Latency (Async)

두 모델 협업 구조 (Pipeline)

자체 모델 간의 순차적 데이터 파이프라인 및 역할 분담 구조 (참고자료)



비용 구조 및 운영 효율

자체 모델 운용 리소스 및 비용 상세 명세 (참고자료)

🔧 초기 구축 리소스 (CAPEX)

학습 데이터 수집 (Claude API) 1회성

4,327건 질의/응답 생성

약 50,000원

임베딩 모델 학습

CPU 기반 학습 (소요시간 약 5분)

전기세 수준

LLM 파인튜닝 (LoRA)

GPU 1시간 (RTX 4070 Ti)

전기세 수준

총 구축 비용

약 5만원

📅 월 운영 리소스 (OPEX)

GCP Cloud Run

CPU 2GB, Request 기반 자동 확장


약 5,000원

Firestore Database

실시간 데이터 읽기/쓰기

약 2,000원

📊 트 운영 비용 비교 시뮬레이션 (월 1,000회 기준)



* 외부 API: 상용 모델 건당 약 \$0.50 기준 / AIPA: 자체 서버 운영비



비용 구조

변동비(API 호출당 과금)를 서버 고정비로 전환하여 운영 예측성 확보



외부 의존성

외부 API 장애 및 정책 변경과 무관하게 독립적인 서비스 운영 가능